AINC
Augmented Intelligence & Cognition Lab.

다중 한국어 음성 코퍼스에서의 Qwen3-ASR 평가 및 추론 파라미터 분석

한신대학교 AI.SW 대학

박소영

2026.7.21

발표 개요

AINC
Augmented Intelligence & Cognition Lab.

Part 1. 투고 논문 보고

- 연구 개요
- 실험 설계
- 주요 결과 및 결론

Part 2. 후속 연구

- UKoSpeech 논문 분석
- 도메인 프롬프트 실험 설계
- 실험 결과 및 향후 계획

Part 1.

다중 한국어 음성 코퍼스에서의 Qwen3-ASR 평가 및 추론 파라미터 분석

음성학회 투고

연구 배경 및 문제 정의

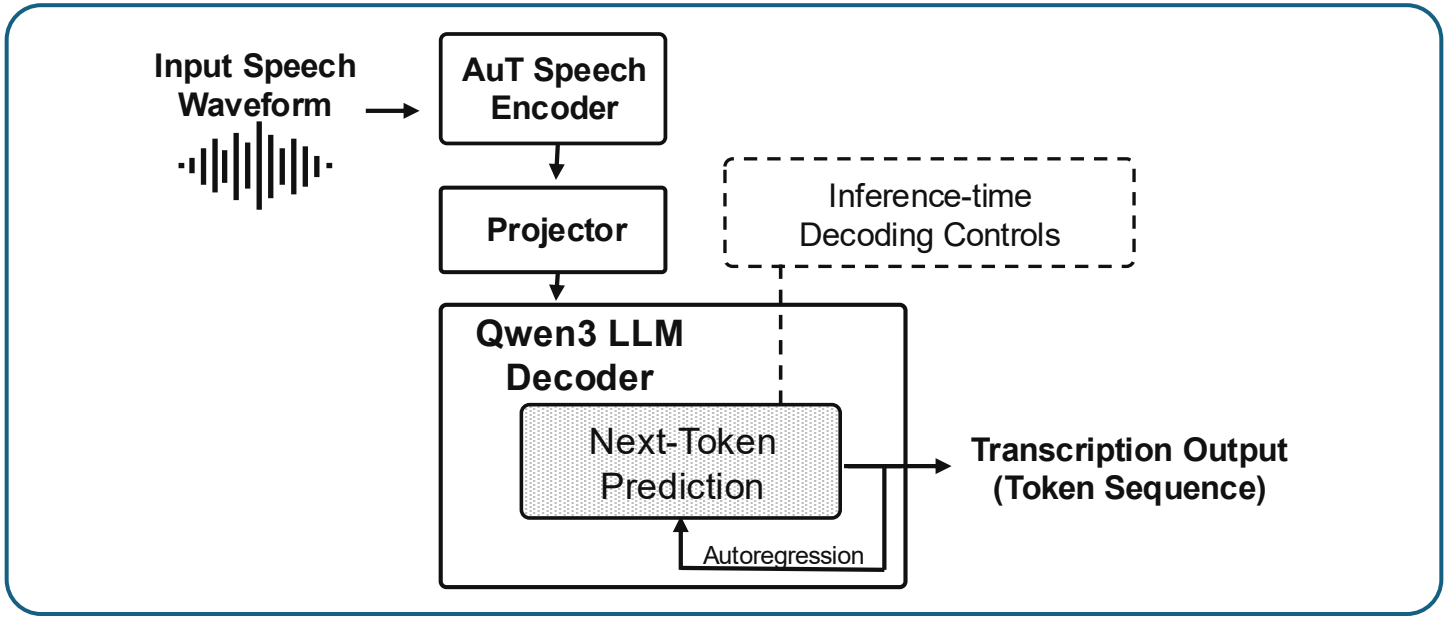
AINC
Augmented Intelligence & Cognition Lab.

연구 배경

(1) LLM 디코더 기반 ASR은 전사 토큰을 자기회귀적으로 생성하므로, 추론 시 디코딩 설정이 출력 전사에 직접 영향을 줄 수 있음

(2) 한국어는 띄어쓰기·발음형/철자형 표기 차이가 크고, 발화 양식·녹음 환경·도메인·화자 특성에 따라 코퍼스마다 인식 난이도가 상이함

(3) 그러나 Qwen3-ASR 등 LLM 기반 ASR에 대한 한국어 다중 코퍼스 평가는 아직 충분하지 않음



연구 목표

AINC
Augmented Intelligence & Cognition Lab.

연구 목표

(1) 한국어 전사에서 Qwen3-ASR의 4개 추론 파라미터의 영향을 분석

(2) 코퍼스별 파라미터 탐색 없이 기본값으로 사용할 수 있는 범용 권장 설정 도출·검증

세부 사항

Model : Qwen3-ASR 0.6B / 1.7B

Dataset : 도메인·음질·화자 특성이 다른 10개 평가셋 (평가셋별 정규화 및 전처리)

Decoding Parameter

language : 인식할 언어를 직접 지정하거나 자동 감지하도록 설정하는설정

max_new_tokens : 생성할 수 있는 최대 토큰 수를 제한하는 설정

temperature : 다음 토큰의 확률 분포를 조절하며, 낮을수록 높은 확률의 토큰을 선택함

repetition_penalty : 이미 생성된 토큰의 재선택 확률을 낮춰 반복을 억제하는 설정

실험 설계 및 평가 지표

AINC
Augmented Intelligence & Cognition Lab.

- 동일 범위를 0.6B와 1.7B에 모두 적용하여 모델 크기에 따른 차이를 함께 분석함
- 탐색은 평가셋별 약 3,000개 발화 표본 사용 (연산 비용 고려, KsponSpeech·Zeroth는 전체 사용)
- NVIDIA A40 × 8 / Qwen3-ASR: vLLM(bfloat16), 32발화 미니배치 / Whisper: HF Transformers(float16)

4개 파라미터를 완전 교차하여 평가셋별·모델별 72개(2×3×4×3) 추론 설정 구성

Parameter	탐색값	개수
language	Korean, auto	2
max_new_tokens	512,1024,2048	3
temperature	0.0, 0.1, 0.2, 0.3	4
repetition_penalty	1.0, 1.1, 1.2	3

음성 분석 지표

AINC
Augmented Intelligence & Cognition Lab.

CER(Character Error Rate, 문자오류율)

- 정답 문자열과 인식 문자열 사이의 문자 단위 오류 비율을 나타내는 지표

WER(Word Error Rate, 단어오류율)

- 정답 문자열과 인식 문자열 사이의 단어(어절) 단위 오류 비율을 나타내는 지표
- 한국어는 띄어쓰기 규약 차이의 영향이 커서, 본 연구는 공백을 제거한 CER(CER_NS)을 주지표로 사용함

본 연구에서는 띄어쓰기를 제거한 후 산출한 CER_NS 를 기준 지표로 사용함

실험 설계 및 평가 지표

AINC
Augmented Intelligence & Cognition Lab.

평균 성능 손실 (regret)

- 성능 손실은 해당 평가셋에서 관측된 최저 오류율 대비 그 설정의 초과분으로 아래와 같이 정의함

$$R(d,\theta) = \mathrm{CER}_{\mathrm{NS}}(d,\theta) - \min_{\theta' \in \Theta'} \mathrm{CER}_{\mathrm{NS}}(d,\theta')$$

- 여러 평가셋에 걸쳐 안정적인 설정을 찾기 위해 성능 손실을 평가셋 전체에 대해 평균을 낸 평균 성능 손실을 권장 설정 선정 기준으로 사용함

$$\overline{R}(\theta) = \frac{1}{D}\sum_{d} R(d,\theta)$$

- 평가셋마다 발화 양식·음질·화자 특성이 달라 동일 조건에서도 기준 성능이 다름
- **평가셋 간 비교 가능한 형태 필요**

결과 1. 평가셋별 기본 성능과 모델 크기 효과

AINC
Augmented Intelligence & Cognition Lab.

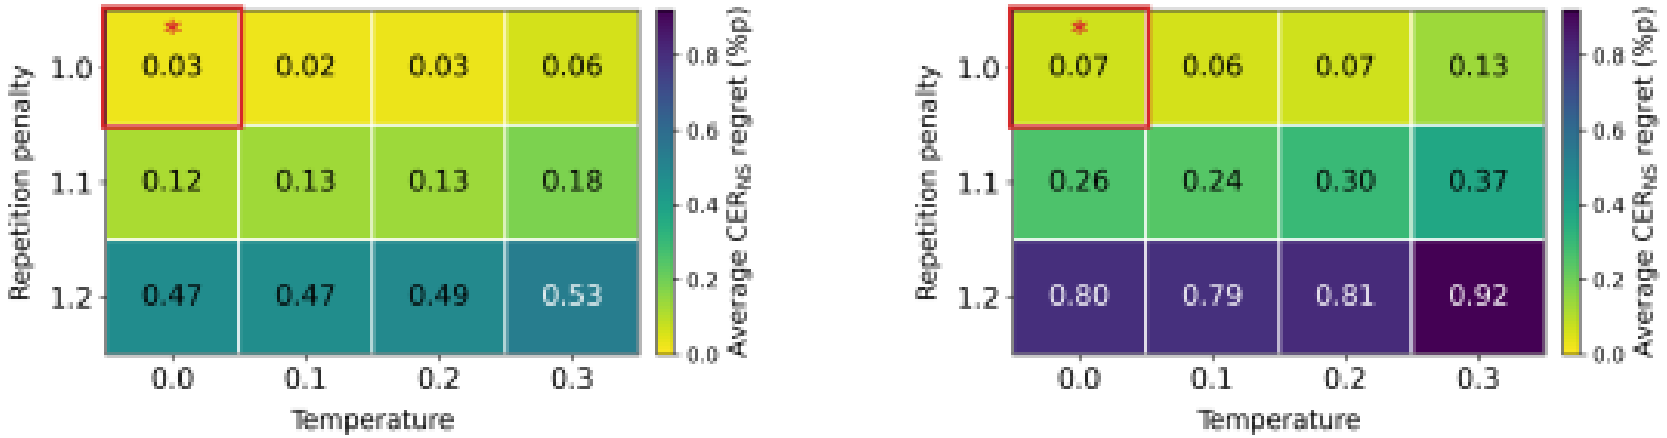
- 모든 평가셋에서 1.7B가 0.6B보다 낮은 CER_NS를 보임
- 평가셋별 최저 CER_NS는 Welfare 2.22%에서 LowQCall 16.48%까지 분포함 — 도메인·음질에 따른 난이도 편차가 큼

DB	모델 크기	temp	rep_penalty	Best CER_{NS} (%)
Kspon (clean)	1.7B	0.2	1.0	12.760
	0.6B	0.0	1.0	15.150
Kspon (other)	1.7B	0.0	1.0	12.600
	0.6B	0.0, 0.1	1.0	15.010
Zeroth -Korean	1.7B	0.2	1.0	3.748
	0.6B	0.1	1.0	4.925
Meeting	1.7B	0.1	1.0	11.164
	0.6B	0.3	1.0	13.023
CustResp	1.7B	0.1	1.0	5.660
	0.6B	0.0	**1.1**	7.917
UnivLec	1.7B	0.1	1.0	9.613
	0.6B	0.2	1.0	11.364
Foreigner	1.7B	0.2	1.0	7.448
	0.6B	0.2	1.0	9.592
LowQCall	1.7B	0.0	1.0	16.481
	0.6B	0.1	1.0	21.110
Num Pattern	1.7B	0.1	**1.1**	7.962
	0.6B	0.1	1.0	8.060
Welfare	1.7B	0.1	1.0	2.220
	0.6B	0.0	1.0	3.368

결과 2. 추론 파라미터 영향 분석

AINC
Augmented Intelligence & Cognition Lab.

- repetition_penalty는 값이 커질수록 평균 성능 손실이 단계적으로 증가하며, 증가 폭은 0.6B에서 더 큼
- temperature는 0.2 이하에서 차이가 제한적이고 0.3부터 평균 손실이 증가함
- language·max_new_tokens는 평균 성능 손실을 유의하게 구분하지 못함
- 설정 민감도는 평가셋별로 상이함 — 최대 평균 손실 폭 기준 Foreigner 3.8%p·LowQCall 3.7%p vs NumPattern 0.15%p



Average CER_{NS} regret (%p) across the ten evaluation sets by temperature and repetition penalty (language = Korean, max_new_tokens = 512) : (a) 1.7B, (b) 0.6B. The asterisk marks the recommended setting.

결과 3. 권장 추론 설정 도출 및 검증

AINC
Augmented Intelligence & Cognition Lab.

- 전체 발화 확보한 8개 평가셋에서 검증 — 표본 대비 차이 대부분 1%p 이내
  (예외: UnivLec·Foreigner는 전체에서 CER_NS 증가)
- repetition_penalty는 1.0이 다수 평가셋에서 최저이거나 최저에 근접함
- temperature는 0.0~0.2 구간의 평균 성능 손실 차이가 매우 작아 확률 표집을 쓰지 않는 0.0을 선택함

따라서 본 연구에서는 아래와 같은 권장 추론 설정을 제안함

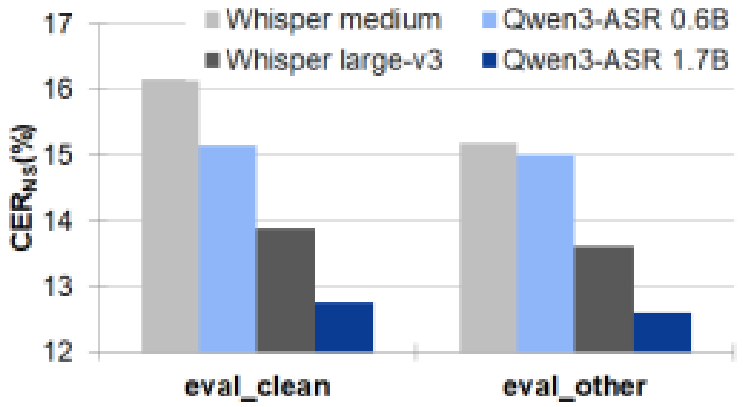
language=korean, max_new_tokens=512, temperature=0.0, repetition_penalty=1.0

결과 4. Whisper 대비 비교

AINC
Augmented Intelligence & Cognition Lab.

- Qwen3-ASR 1.7B : 12.76/12.60% < large-v3 : 13.89/13.62%
- Qwen3-ASR 0.6B : __.__/__.__% vs Whisper medium : __.__/__.__% ※ 실측값 기입 필요(기존 값은 1.7B 행 복사 오류)

- 단, KsponSpeech 두 평가셋에 한정된 비교이므로 한국어 전반의 우위를 단정할 수 없음



CER_{NS} of Qwen3-ASR and Whisper on KsponSpeech eval_clean and eval_other. Models are paired by comparable scale (1.7B–large-v3, 0.6B–medium), and each uses its best decoding setting on these sets. Lower is better.

Part 2.

도메인 프롬프트 기반 한국어 Whisper 적응

- UKoSpeech 핵심 가설의 소규모 검증

UKoSpeech 논문 개요

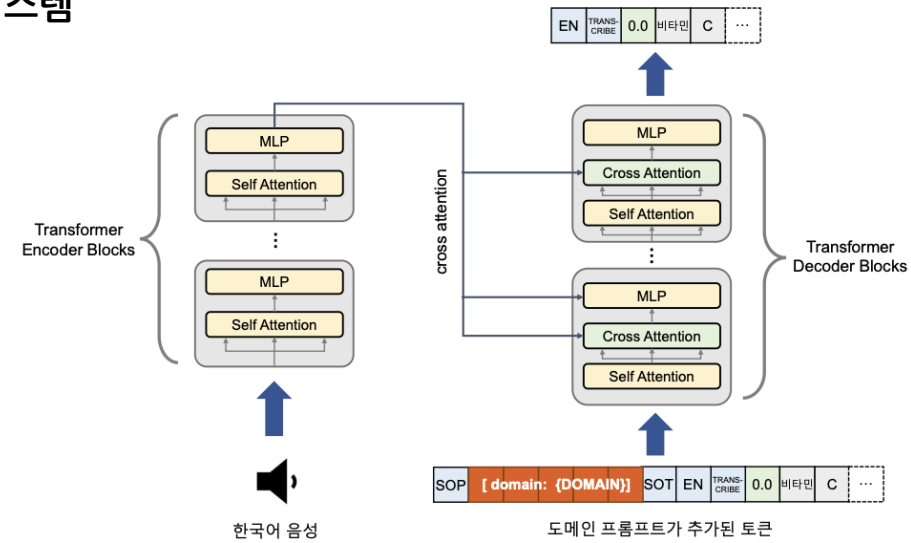
AINC
Augmented Intelligence & Cognition Lab.

[논문] UKoSpeech: 다양한 도메인을 위한 범용 한국어 음성인식 시스템

연구 배경

(1) 한국어 도메인 특화 음성·텍스트 데이터가 부족함

(2) 범용 Whisper는 전문용어·특정 문맥에 충분히 적응하지 못함



제안 방법

(1) (1) 데이터 큐레이션

유튜브의 인간 작성 자막과 음성을 수집하고, WhisperX 참조 전사와 후보 자막의 CER를 비교해 품질이 낮은 샘플을 제거함 — 금융·의료·법률 약 12시간 데이터 구축

(2) 도메인 프롬프트 학습

Whisper 디코더 앞부분에 {도메인: 의료} 같은 태그를 넣고, 음성과 도메인 정보를 함께 조건으로 삼아 전사를 학습

보고 성능: Whisper-large-v3 CER 5.17% → UKoSpeech 3.29% (상대 약 36% 감소)

UKoSpeech 핵심 결과: 프롬프트 ablation

AINC
Augmented Intelligence & Cognition Lab.

[논문] UKoSpeech: 다양한 도메인을 위한 범용 한국어 음성인식 시스템

- 동일 평가셋에서 '태그 유무 × 조건 학습 여부' 2×2 조합의 전체 CER(%)을 비교한 논문 ablation
- 기본 Whisper에 태그만 삽입 시 CER 4.04 → 9.34로 악화
- 동일 태그가 조건 학습된 모델에서는 3.86 → 3.29로 개선

도메인 태그 개수	WER (%)				CER (%)			
	금융	의료	법률	전체	금융	의료	법률	전체
Whisper-large-v3								
10	23.34	16.33	25.49	17.94	14.43	6.43	15.31	8.63
1	38.12	19.61	23.91	20.55	28.01	7.14	13.13	9.34
태그 없음	**12.67**	**15.93**	**15.07**	**15.43**	**3.76**	**4.02**	**3.96**	**4.04**
UKoSpeech								
10	11.75	**11.56**	**13.79**	**11.90**	**3.31**	**2.98**	**3.78**	**3.07**
1	**11.73**	12.61	14.35	12.74	3.42	3.26	3.84	3.29
태그 없음	12.48	15.74	15.95	15.39	3.68	4.05	3.84	3.86

파인튜닝하지 않은 기본 모델에 도메인 프롬프트 태그를 추가한 결과 성능이 악화됨

프롬프트 태그는 조건 학습된 모델에서만 성능을 개선함
→ 본 후속 실험의 검증 대상

표 3. 도메인 태그 개수에 따른 모델 성능 비교. 굵게 표시된 값은 각 도메인에서의 최소 오류율을 나타낸다.

실험 설계

AINC
Augmented Intelligence & Cognition Lab.

- 이 2×2 구조가 whisper-small·한국어 회의 데이터에서 재현되는지, 세 가지 질문으로 분해해 검증함
- 기본 Whisper에 도메인 프롬프트만 삽입하면 개선되는가 (조건 B)
- 도메인 프롬프트를 조건으로 LoRA 학습하면 개선되는가 (조건 C)
- 학습된 모델의 추론 시 프롬프트 기여가 존재하는가 (조건 C vs D)

	프롬프트 없음	프롬프트 추가
기본 whisper - small	A	B
LoRA 학습모델	D	C

- 검증 범위: 논문 완전 재현이 아닌 핵심 가설의 소규모 검증

  whisper-small + LoRA, 회의 음성 코퍼스, 도메인 교육·의료·정치
- 4개 조건 동일 test 375발화, 동일 디코딩 설정

(language=korean, temperature=0.0, repetition_penalty=1.0, greedy) — Part 1 권장 설정과 동일 계열

- 프롬프트 형식 고정: {도메인: 교육}, 손실은 전사 토큰에만 적용(프롬프트·제어 토큰 masking)

실험 설계 - 사용 데이터셋 및 학습 설정

AINC
Augmented Intelligence & Cognition Lab.

- **데이터 구축 — 원본 회의 ZIP에서 아래 절차로 생성**
- 라벨 ZIP(회의별 JSON)과 음성 ZIP을 meeting_id로 연결, 발화 구간(1~30초)만 절단 추출
- 전사 정규화: 이중 전사 (발음)/(표준)은 표준 표기 선택, 전문용어 마킹 (@용어)는 용어 보존, 배경음 태그(/(bgm) 등) 제거, 익명화(@이름N)·전사불능((())) 발화 제외
- 도메인별 500발화로 균형화, 회의 단위 train/dev/test 분할로 화자·주제 누수 차단

	회의	발화	음성 시간
Train	6	750	1.54 h
Dev	3	375	0.83 h
Test	3	375	0.77 h
계	12	1,500	3.14 h

- **학습 설정**
- 기반 모델: openai/whisper-small (242.6M)
- LoRA: r=8, alpha=16, dropout=0.05, 대상 q_proj·v_proj → 학습 파라미터 884,736개(전체의 0.36%)
- 학습: 3 epoch, batch 8, lr 1e-4, AdamW, gradient checkpointing
- 환경: RTX 5090, PyTorch 2.11.0+cu130, transformers 5.14.1, peft 0.19.1
- 학습 시간 153초, best eval_loss 0.578(epoch 2 체크포인트 사용)

실험 결과 1. 조건별 전체 성능

AINC
Augmented Intelligence & Cognition Lab.

- 조건 A~D를 동일한 test 375발화·동일 디코딩 설정으로 평가한 CER_NS 비교
- B는 A 대비 +7.38%p 악화 → 프롬프트 단독 삽입은 역효과 (논문 ablation과 동일 방향)
- D는 A 대비 −4.24%p → LoRA 도메인 적응 단독 효과
- C는 A 대비 −5.51%p(상대 35.7% 감소), D 대비 −1.27%p → 조건 학습된 프롬프트의 추가 기여 확인
- 논문 2×2 ablation과 4개 칸 모두 방향 일치

조건	모델	프롬프트	CER_NS(%)
A	기본 small	×	15.41
B	기본 small	○	22.79
C	LoRA	○	**9.90**
D	LoRA	×	11.17

전사 예시 (정치 도메인 test 발화):

정답: "연령 구분 없이 예약 가능하고 백신은 8월 16일 이후에 접종을 하게 됩니다 …"

A: 선두부 누락("백신은 8월…"부터 시작) / B: "전국은 백신을 접종하는 것에 대해" 반복 / C: 정답과 일치

실험 결과 2. 도메인별 성능 및 오류 유형

AINC
Augmented Intelligence & Cognition Lab.

- 동일 평가를 도메인별로 분해하고(표: CER_NS %), 조건별 오류 사례를 정성 분석함
- 기본 모델 오류율이 가장 높은 정치에서 개선 폭 최대(상대 48.0%)
- 프롬프트 추가 기여(C vs D)는 도메인별 상이: 정치 뚜렷, 의료는 관측되지 않음 → 프롬프트 효과의 도메인 의존성은 추가 검증 필요
- 조건 B 오류 유형: 프롬프트 문자열을 직전 발화 문맥으로 처리하여 태그 어휘를 반복 생성하는 사례 확인 (예: 정치 도메인에서 "정치에 대한" 반복 출력, 5건)
- 기본 모델 A의 발화 절반 이하 조기 종료 12건 중 대부분이 C에서 복원

도메인	A	C	상대 감소
교육	10.04	7.67	23.7%
의료	14.88	11.05	25.7%
정치	21.82	11.34	48.0%
전체	15.41	9.90	35.7%

진행 상황: whisper-large-v3 확장 실험

AINC
Augmented Intelligence & Cognition Lab.

```
ubuntu@86dab49eb929:/workspace/project$ python scripts/build_dataset.py \
  --config configs/large_v3.toml \
  --label-zip "$LABEL_ZIP_PATH" \
  --audio-zip "$AUDIO_ZIP_PATH" \
  --output-dir "$LARGE_DATA_DIR" \
  --overwrite
[warn] Audio-boundary/decode failures reduced the balanced target from 4258 to 4147 utterances per domain.
train: 48 meetings, 9957 utterances, 72947.2s
dev: 6 meetings, 1171 utterances, 8344.5s
test: 6 meetings, 1313 utterances, 10237.5s
Build report: /workspace/project/data/large-v3/build_report.json
ubuntu@86dab49eb929:/workspace/project$ python scripts/validate_manifests.py \
  --data-dir "$LARGE_DATA_DIR" \
  --domains 교육 의료 정치
{
  "train": {
    "rows": 9957,
    "meetings": 48,
    "domains": {
      "교육": 3404,
      "의료": 3244,
      "정치": 3309
    },
    "wav_headers_checked": 9957
  },
  "dev": {
    "rows": 1171,
    "meetings": 6,
    "domains": {
      "교육": 316,
      "의료": 469,
      "정치": 386
    },
    "wav_headers_checked": 1171
  },
  "test": {
    "rows": 1313,
    "meetings": 6,
    "domains": {
      "교육": 427,
      "의료": 434,
      "정치": 452
    },
    "wav_headers_checked": 1313
  }
}
Manifest validation passed: no meeting leakage; paths and WAV headers are valid.
```

확장 데이터셋 구축 완료

· train 9,957 / dev 1,171 / test 1,313 발화

· 회의 60개, 약 25.4시간, 도메인 균형 유지

· 무결성 검증 통과 (회의 누수 없음, 경로·WAV 헤더 확인)

small과 동일 프로토콜로 LoRA 학습 진행 중

Part 2 요약 및 향후 계획

AINC
Augmented Intelligence & Cognition Lab.

요약

(1) UKoSpeech의 ablation 경향을 whisper-small·회의 코퍼스에서 재현 — 프롬프트 단독은 악화(B), 조건 학습 시 최적(C: CER_NS 15.41 → 9.90)

(2) 학습 파라미터 0.36%·학습 153초의 저비용 검증 → 단일 모델의 조건부 다중 도메인 처리 가능성 확인

한계 및 향후 계획

(1) 도메인별 회의 4개·단일 seed 소규모 실험 — 논문(large-v3) 수치와 직접 비교 불가

(2) whisper-large-v3 동일 프로토콜 검증: 확장 데이터 12,441발화 구축 완료, 학습 진행 중

(3) 회의 수 확대·반복 실험, 단일/다중 태그 비교, 전문용어(term 마킹) 단위 오류 분석

Appendix 1. 10종 데이터셋

AINC
Augmented Intelligence & Cognition Lab.

DB	발화수	전사 유형	주요 전처리
KsponSpeech (clean/other)	3,000	정서법·발음열	• o/ n/ u/ b/ l/ 표지 처리 • – / + * - @ $ ^ & [] = : ; , 제거 • – #→샵, %는 퍼센트/프로 처리
Zeroth -Korean	457	정서법	• 문장부호 제거 • 공백 정규화
Meeting	16,113	정서법·발음열	• 이중 전사 선택 • o/ n/ u/ b/ l/ 표지 처리 • 잡음·간투 표지 처리 • 특수기호 제거
CustResp	21,105	정서법·발음열	• 이중 전사 선택 • o/ n/ u/ b/ l/ 표지 처리 • 잡음·간투 표지 처리 • 특수기호 제거
UnivLec	193,257	정서법	• 한영 병기에서 한국어 선택 • 문장부호 제거
Foreigner	115,785	정서법	• X/형 간투·비언어 표지 제거 • X+형 말더듬 표지 제거 • BOM 제거, 문장부호 제거
NumPattern	489,607	정서법 (숫자 한글 표기)	• 대괄호 표지 제거 • 문장부호 제거 • 아라비아 숫자 표기 안함
LowQCall	39,916	정서법	• o/, n/ 제거, • (A)/(B)는 첫 번째 표기 선택 • 문장부호 제거
Welfare	223,546	정서법	• 문장부호 제거 • 공백 정규화

감사합니다. Q&A